

Optimización de costos

Costo actual: **USD 0 / mes**

Servicio	Plan	Límite	Uso real del proyecto
Telegram Bot API	gratis	sin límite práctico	unos mensajes por día
Make	Free	1.000 operaciones/mes	~3-4 ops por registro/consulta; agregar desde el sitio suma otro ~3 (webhook + Gemini + Add a Row) → margen enorme
Google Gemini API (bot)	Free tier	límites por minuto y por día	1-2 llamadas por mensaje o por acción del sitio
Google Gemini API (Cinefilla)	Free tier, proyecto aparte	límites por minuto y por día, propios	1 llamada por pregunta (hasta 3 si tiene que corregir una recomendación); ~10.000 tokens de contexto cada una
Google Sheets	gratis	10M celdas	~23.000 celdas (dos pestañas)
TMDB API	gratis	límite por IP, altísimo	la sincronización diaria (solo lo nuevo) + consultas en vivo desde el navegador de cada visitante
Vercel	Hobby (gratis)	100 GB/mes de tráfico; funciones con cupo mensual	trivial; 1 función (/api/chat)
GitHub Actions	gratis (repo público)	minutos ilimitados en repos públicos	1 corrida diaria de ~2-3 minutos
Total			USD 0

Estrategia por tarea

El principio: **modelo económico para lo mecánico, modelo capaz para el razonamiento, procesamiento por lotes para el volumen no urgente.**

Tarea	Naturaleza	Elección	Por qué
Clasificar intención + extraer ficha	Mecánico, repetitivo, alto volumen potencial	Gemini Flash-Lite (gratis)	Tarea acotada con esquema fijo; un modelo chico la resuelve igual de bien.
Responder consultas / recomendar (Telegram)	Razonamiento sobre ~1.300 filas de contexto	Gemini Flash-Lite con ventana larga	Alcanza para listar y recomendar.

Tarea	Naturaleza	Elección	Por qué
Chat de cine del sitio (Cinefilla)	Conversación, en tiempo real, abierta al público	Gemini Flash-Lite + controles del lado del servidor	Ver "El caso Cinefilla" abajo: lo barato y rápido, compensado con verificación propia en vez de un modelo más caro.
Pósters, reparto, duración, sinopsis, recomendadores, perfil de gusto (~1.250 películas c/u)	Volumen alto, no urgente	GitHub Actions + scripts + TMDb , NO Make	~1.250 llamadas por Make = más que el límite mensual entero, por cada archivo. Un script lo hace en minutos, gratis; corriendo solo de noche, además no depende de nadie.
Completar director/año/país/género al agregar un título desde el sitio	Puntual, un solo ítem por vez	Gemini vía Make , sí	Acá sí tiene sentido: es 1 llamada, en tiempo real, no un backfill.
Búsquedas en vivo (persona, país, póster que falta)	Puntual, la pide un visitante	TMDb directo desde el navegador	Sin servidor ni IA: es una consulta a una API gratuita de solo lectura.

El caso Cinefilla

El chat del sitio es la única pieza abierta al público que llama a una IA, así que es donde más importa el costo (aunque sea "cupo gratis", se agota).

- **Contexto a la medida.** La primera versión mandaba el catálogo entero con todo el detalle en cada pregunta: 29.000 tokens. A las ~6 preguntas seguidas agotaba el cupo gratis por minuto. Ahora manda el detalle solo de las películas relacionadas con la pregunta (las de ese director, ese título, ese género) y del resto solo título y año, para saber qué está visto. ~~**10.000 tokens, un tercio**~~.
- **Cuentas hechas por código, no por la IA.** Totales, visionados por año y conteos por director van precalculados. Más barato (menos razonamiento) y correcto (el modelo sumaba mal: decía 20 visionados de Tarantino y son 25).
- **Verificación en vez de un modelo más caro.** El modelo rápido a veces recomienda algo ya visto. En lugar de pasar a un modelo mayor (que respondía mejor pero tardaba ~30 segundos), la función revisa cada recomendación contra el catálogo real y repite la consulta solo si hace falta.
- **Límites para un sitio público.** 15 consultas cada 10 minutos por persona, 600 caracteres por mensaje, las últimas 10 intervenciones de la charla. Y la clave en un **proyecto de Google aparte**: si alguien agota el cupo del chat, el bot de Telegram sigue funcionando.
- **Fuera de tema, en una línea.** Lo que no es de cine recibe una respuesta fija y corta, sin gastar tokens en contestar.

Qué NO hacer

- **No** mandar los backfills por Make. Un backfill de 1.000+ ítems agota el plan Free en una sola corrida. Van por la sincronización diaria.
- **No** llamar a la IA para lo que resuelve una fórmula o un script. `id`, `numero` y `es_revisionado` se calculan con `COUNTIF` en la hoja; los conteos de Cinefilla, en la función.

- **No** poner la clave de una IA en el navegador. La de TMDB sí está en el sitio (es de solo lectura y gratuita); la de Gemini vive en Vercel y el sitio solo habla con la función.

Si el proyecto escalara

Disparador	Qué cambiar
> 1.000 ops/mes en Make	Plan Core de Make (USD 9/mes, 10.000 ops) o migrar la orquestación a non self-hosted (USD 5-10/mes de VPS).
Se supera la cuota gratis de Gemini	Pago por uso de Gemini Flash-Lite: fracciones de centavo por mensaje.
Mucho tráfico en Cinefilla	Cache de respuestas frecuentes; bajar el límite por persona; o mover la detección de "fuera de tema" a una regla barata antes de llamar a la IA.
Consultas con mucho más volumen de catálogo	Embeddings + búsqueda por similitud → se le pasa a la IA solo el top-k, no la lista de títulos completa.
Se quiere calidad de razonamiento superior	Solo la rama de consultas a un modelo mayor (Gemini Pro / Claude); la de registro sigue en Flash-Lite.