

Optimización de costos

Costo actual: **USD 0 / mes**

Servicio	Plan	Límite	Uso real del proyecto
Telegram Bot API	gratis	sin límite práctico	unos mensajes por día
Make	Free	1.000 operaciones/mes	~3-4 ops por registro/consulta; agregar desde el sitio suma otro ~3 (webhook + Gemini + Add a Row) → margen enorme
Google Gemini API	Free tier	~15 req/min, cuota diaria amplia	1-2 llamadas por mensaje o por acción del sitio
Google Sheets	gratis	10M celdas	~23.000 celdas (dos pestañas)
TMDB API	gratis	límite altísimo	solo en backfills manuales
Vercel	Hobby (gratis)	100 GB/mes de tráfico	trivial
Total			USD 0

Estrategia por tarea

El principio: **modelo económico para lo mecánico, modelo capaz para el razonamiento, procesamiento por lotes para el volumen no urgente.**

Tarea	Naturaleza	Elección	Por qué
Clasificar intención + extraer ficha	Mecánico, repetitivo, alto volumen potencial	Gemini Flash (gratis)	Tarea acotada con esquema fijo; un modelo chico la resuelve igual de bien.
Responder consultas / recomendar	Razonamiento sobre ~1.280 filas de contexto	Gemini Flash con ventana larga	Alcanza para listar y recomendar. Si se quisiera más matiz: Gemini Pro o Claude, pagando por uso.
Backfill de pósters, reparto, duración, sinopsis y similitud (~1.230 películas c/u)	Volumen alto, no urgente , se recorre entero cada vez que hace falta	Scripts locales + TMDB , NO Make	~1.230 llamadas por Make = más que el límite mensual entero, por cada archivo. Un script en la máquina lo hace en minutos, gratis.
Completar director/año/país/género al agregar un título desde el sitio	Puntual, un solo ítem por vez	Gemini vía Make , sí	Acá sí tiene sentido: es 1 llamada, en tiempo real, no un backfill.

Tarea	Naturaleza	Elección	Por qué
Backfill de embeddings (si se hace)	Volumen alto, no urgente	Lote (Batch API) o script local	Nunca en el flujo en tiempo real.

Qué NO hacer

- **No** mandar los backfills por Make. Un backfill de 1.000+ ítems agota el plan Free en una sola corrida. Los backfills van por script local.
- **No** llamar a la IA para lo que resuelve una fórmula. `id`, `numero` y `es_revisionado` se calculan con `COUNTIF` en la hoja, no con Gemini.
- **No** leer el catálogo entero desde la IA en cada consulta si el volumen creciera mucho. Hoy ~1.280 filas entran holgadas en contexto; si llegara a decenas de miles, convendría filtrar antes (por director, género) y pasar solo el subconjunto.

Si el proyecto escalara

Disparador	Qué cambiar
> 1.000 ops/mes en Make	Plan Core de Make (USD 9/mes, 10.000 ops) o migrar la orquestación a non self-hosted (USD 5-10/mes de VPS).
Se supera la cuota gratis de Gemini	Pago por uso de Gemini Flash: fracciones de centavo por mensaje.
Consultas con mucho más volumen de catálogo	Embeddings + búsqueda por similitud en el navegador → se le pasa a la IA solo el top-k, no todo.
Se quiere calidad de razonamiento superior	Solo la rama de consultas a un modelo mayor (Gemini Pro / Claude); la de registro sigue en Flash.